

生成模型 1: DDPM

Step 1: 数据向量化与建模对象

设原始数据为图像等高维对象。经过固定的预处理（如解码、缩放、标准化）后，每个样本记为向量或张量

$$x_0 \in \mathbb{R}^d. \quad (1)$$

例如， $H \times W$ 的灰度图可以展平为 $d = HW$ 维向量，RGB 图像可以展平为 $d = 3HW$ 维向量。本文统一把数据表示写成 $x_0 \in \mathbb{R}^d$ 。

假设这些样本是从某个真实但未知的总体分布抽样得到：

$$x_0 \sim p_{\text{data}}(x_0). \quad (2)$$

这里的 p_{data} 是一个理论上的真实分布，无法显式写出；训练时用经验平均近似关于 p_{data} 的期望，即

$$\mathbb{E}_{x_0 \sim p_{\text{data}}}[f(x_0)] \approx \frac{1}{N} \sum_{i=1}^N f(x_0^{(i)}). \quad (3)$$

在理论上， p_{data} 表示真实数据的总体分布，一般无法显式写出（如果你都知道的话，那就不需学一个生成模型了）；训练时只能通过有限样本的经验分布和参数化模型 p_θ 去近似它。目标是构造一个参数化模型分布 $p_\theta(x_0)$ ，在分布意义上尽量接近 $p_{\text{data}}(x_0)$ ，从而在模型中重现真实数据的统计结构（生成模型的本质）。

Step 2: 目标函数——从 KL 到最大似然

我们希望 $p_\theta(x_0)$ 逼近 $p_{\text{data}}(x_0)$ ，一个自然的度量是 KL 散度：

$$\text{KL}(p_{\text{data}} \parallel p_\theta) = \mathbb{E}_{x_0 \sim p_{\text{data}}}[\log p_{\text{data}}(x_0) - \log p_\theta(x_0)]. \quad (4)$$

第一项 $\mathbb{E}[\log p_{\text{data}}(x_0)]$ 与 θ 无关，因此

$$\arg \min_{\theta} \text{KL}(p_{\text{data}} \parallel p_\theta) = \arg \max_{\theta} \mathbb{E}_{x_0 \sim p_{\text{data}}}[\log p_\theta(x_0)]. \quad (5)$$

这就是最大似然目标：

$$\max_{\theta} \mathbb{E}_{x_0 \sim p_{\text{data}}}[\log p_\theta(x_0)]. \quad (6)$$

用样本平均近似，有经验目标

$$\max_{\theta} \frac{1}{N} \sum_{i=1}^N \log p_\theta(x_0^{(i)}). \quad (7)$$

问题在于：对高维图像，直接构造、优化 $p_\theta(x_0)$ 非常困难。DDPM 的核心思想是：引入一个可控的前向“加噪”过程 $q(x_{1:T} | x_0)$ ，再构造一个反向生成过程 $p_\theta(x_{0:T})$ ，通过变分下界把式 (6) 中对 $\log p_\theta(x_0)$ 的优化，转化为一系列局部、简单的子问题。

在 DDPM 的框架中，结论告诉我们，实际最终优化目标等价于：一个关于“噪声预测误差”的期望损失。“补充”中给出了原因。

Step 3: 模型结构——前向扩散与反向生成链

本步回答：在什么空间上、用什么随机过程来建模 $p_\theta(x_0)$ 。

前向扩散过程 $q(x_{1:T} | x_0)$

选择一个步数 T ，给定噪声调度 $\{\beta_t\}_{t=1}^T \subset (0, 1)$ ，定义

$$\alpha_t = 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s. \quad (8)$$

前向过程 q 是一个从 x_0 出发的马尔可夫链：

$$q(x_{1:T} | x_0) = \prod_{t=1}^T q(x_t | x_{t-1}), \quad (9)$$

其中每一步都是加各向同性高斯噪声：

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t} x_{t-1}, (1 - \alpha_t)I). \quad (10)$$

由于高斯的叠加仍为高斯，可以直接写出 $q(x_t | x_0)$ 的闭式：

$$q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I). \quad (11)$$

即我们可以在一步中构造任意时间步的带噪样本：

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I). \quad (12)$$

注意，这里的 ε 维度为 d ， I 维度为 $d * d$ 。训练时，式 (12) 用于从干净样本 x_0 直接生成任意噪声等级 t 的输入 x_t 。

反向生成模型 $p_\theta(x_{0:T})$

为了生成数据，我们需要一个从纯噪声“反向走向”数据的过程。引入反向马尔可夫链：

$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^T p_\theta(x_{t-1} | x_t). \quad (13)$$

通常选顶层先验为标准高斯：

$$p(x_T) = \mathcal{N}(0, I). \quad (14)$$

对每个反向条件分布 $p_\theta(x_{t-1} | x_t)$ ，假设其为高斯：

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(\mu_\theta(x_t, t), \Sigma_t), \quad (15)$$

其中 Σ_t 为仅依赖时间步 t 的对角协方差，典型设定为

$$\Sigma_t = \sigma_t^2 I. \quad (16)$$

这个 σ_t^2 通常不是随便取的，而是从前向过程的噪声调度推出来的一个函数，例如直接选为前向后验的方差 $\tilde{\beta}_t$ ，或者在 β_t 和 $\tilde{\beta}_t$ 之间做插值。通过这个马尔可夫链，边缘分布 $p_\theta(x_0)$ 就由 $\{p_\theta(x_{t-1} | x_t)\}$ 诱导出来。

核心 DL 学习目标具体是什么？以及细节补充？

模型框架已经搭好了。我们要清楚：1. 什么部分是可学习的？或者说，学习目标是什么。给答案：学习目标是一个噪声预测网络，我们希望它尽可能贴近原噪声，即高斯标准噪声；为什么预测噪声就可以？补充中给了原因。2. 反向过程中的反向均值 μ 具体形式是什么？

先解决第一个问题!! 由前向过程式 (12) 可知，在给定 x_0 的情况下， x_t 满足

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I). \quad (17)$$

因此， x_t 可以看作“衰减后的 x_0 加一层高斯噪声”。DDPM 的学习目标是这层噪声，定义一个随时间步变化的噪声预测网络（例如 U-Net，现成）：希望满足

$$\varepsilon_\theta(x_t, t) \rightarrow \varepsilon. \quad (19)$$

其中左边是预测的，右边是高斯标准噪声。

再解决第 2 个问题!! 给定 (x_t, t) 和网络输出 $\varepsilon_\theta(x_t, t)$ ，可以构造对 x_0 的估计：

$$\hat{x}_{0,\theta}(x_t, t) = \frac{1}{\sqrt{\bar{\alpha}_t}} (x_t - \sqrt{1 - \bar{\alpha}_t} \varepsilon_\theta(x_t, t)). \quad (20)$$

利用高斯条件分布公式，可以把反向均值 $\mu_\theta(x_t, t)$ 写成

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \varepsilon_\theta(x_t, t) \right). \quad (21)$$

于是反向条件分布为

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}\left(\frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \varepsilon_\theta(x_t, t) \right), \sigma_t^2 I\right). \quad (22)$$

实现上，网络直接输出 $\varepsilon_\theta(x_t, t)$ ， $\mu_\theta(x_t, t)$ 按式 (21) 计算。

到此为止，模型结构（Step 3）已经完整定义：前向 $q(x_{1:T} | x_0)$ 固定、只用于加噪；反向 $p_\theta(x_{0:T})$ 由噪声预测网络 ε_θ 决定。

Step 4: 训练算法

设 batch 大小为 B ，一次迭代过程为：

1. 从数据集中采样 mini-batch $\{x_0^{(i)}\}_{i=1}^B$ 。

2. 对每个样本 i ，采样时间步

$$t^{(i)} \sim \text{Uniform}\{1, \dots, T\}. \quad (24)$$

3. 对每个样本 i ，采样高斯噪声

$$\varepsilon^{(i)} \sim \mathcal{N}(0, I), \quad (25)$$

并按式 (12) 构造带噪样本

$$x_{t^{(i)}}^{(i)} = \sqrt{\bar{\alpha}_{t^{(i)}}} x_0^{(i)} + \sqrt{1 - \bar{\alpha}_{t^{(i)}}} \varepsilon^{(i)}. \quad (26)$$

4. 将 $(x_{t^{(i)}}^{(i)}, t^{(i)})$ 输入网络（这是已知的，例如 U-Net），得到噪声预测

$$\hat{\varepsilon}_\theta^{(i)} = \varepsilon_\theta(x_{t^{(i)}}^{(i)}, t^{(i)}). \quad (27)$$

5. 计算 mini-batch 损失 (MSE)

$$\mathcal{L}_B(\theta) = \frac{1}{B} \sum_{i=1}^B w_{t^{(i)}} \left\| \varepsilon^{(i)} - \hat{\varepsilon}_\theta^{(i)} \right\|^2. \quad (28)$$

6. 按梯度法更新参数

$$\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}_B(\theta), \quad (29)$$

其中 $\eta > 0$ 为学习率，优化器可以是 SGD / Adam 等。

在训练过程中反复执行上述步骤，直到损失和生成质量收敛，得到训练好的参数 $\hat{\theta}$ 。此时，Step 2 的最大似然目标在 DDPM 框架下已通过 Step 4 的噪声预测训练近似实现。

Step 5: 测试算法

训练完成后，使用 $\hat{\theta}$ 从模型中生成样本或作为先验服务于下游任务。

无条件采样：从噪声生成数据

生成一条新样本 \tilde{x}_0 的过程为：

1. 初始化

$$x_T \sim \mathcal{N}(0, I). \quad (30)$$

2. 对 $t = T, T-1, \dots, 1$ 依次执行：

- (a) 计算噪声预测

$$\hat{\varepsilon}_t = \varepsilon_{\hat{\theta}}(x_t, t). \quad (31)$$

(b) 按式 (21) 计算反向均值

$$\mu_{\hat{\theta}}(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \hat{\epsilon}_t \right). \quad (32)$$

(c) 若 $t > 1$, 采样下一步

$$x_{t-1} \sim \mathcal{N}(\mu_{\hat{\theta}}(x_t, t), \sigma_t^2 I); \quad (33)$$

若 $t = 1$, 令

$$x_0 = \mu_{\hat{\theta}}(x_1, 1). \quad (34)$$

3. 输出最终生成样本

$$\tilde{x}_0 = x_0. \quad (35)$$

此时 \tilde{x}_0 就是从模型分布 $p_{\hat{\theta}}(x_0)$ 中采样得到的高维样本, 例如一张新生成的图像。

Step6: 应用场景

在实际应用中, DDPM 及其变体可以用于:

1. **生成“像真的一样”的样本.** 例子: 头像生成 / 换头像你给系统几张自己喜欢的风格图 (动漫头像、油画风、ins 风自拍)。模型学到“人脸长什么样”“这种风格的颜色和纹理是什么分布”。然后从 $p_{\theta}(x)$ 里采样出一大堆从未在训练集中出现过、但“看起来就像真实自拍/插画”的新头像, 让你挑着用。

2. **条件生成、修补、反演.** 例子: 把游客照里的路人“干净地抹掉”你拍了一张风景照, 前面有路人、垃圾桶。条件: 给模型“原始图片 + 一个 mask (标出要抹掉的区域)”。模型基于学到的 p_{θ} (干净风景图), 在被遮住的区域补出合理的天空、海面、路面, 而不是乱涂颜色。结果: 看起来像你本来就拍到了一个没人、干净的场景。

3. **提供强先验 (当作“数据分布的经验”来用).** 例子: 手机里把糊掉的夜景照片修清晰夜景拍糊了, 噪声很多, 细节看不清。相机 APP 背后有一个学好的 p_{θ} (自然场景照片), 知道“正常的夜景大概是什么纹理、轮廓和光斑分布”。在做“从模糊图恢复清晰图”这个反问题时, 它把这个 p_{θ} 当先验: 排除那些虽然数学上也能解释模糊图, 但看起来很怪的解; 优先选择“符合真实照片统计结构”的那一类解。用户感知就是: 明明原图糊得一塌糊涂, 点一下“增强”, 出来的照片细节合理得多。

补充 1：为什么 \max 似然等价于 \max 噪声期望？

本节说明：为什么 Step 2 中的最大似然目标可以转化为 Step 4 中的“噪声预测误差”损失。

(1) **变分下界 (ELBO)** 对任意固定的前向分布 $q(x_{1:T} | x_0)$ ，有

$$\log p_\theta(x_0) = \log \int p_\theta(x_{0:T}) dx_{1:T} \quad (1)$$

$$= \log \int \frac{p_\theta(x_{0:T})}{q(x_{1:T} | x_0)} q(x_{1:T} | x_0) dx_{1:T} \quad (2)$$

$$\geq \mathbb{E}_{q(x_{1:T} | x_0)} [\log p_\theta(x_{0:T}) - \log q(x_{1:T} | x_0)] \quad (3)$$

$$\equiv \mathcal{L}_{\text{ELBO}}(x_0; \theta), \quad (4)$$

其中不等号来自 Jensen 不等式。对 $x_0 \sim p_{\text{data}}$ 取期望，得到

$$\mathbb{E}_{p_{\text{data}}} [\log p_\theta(x_0)] \geq \mathbb{E}_{p_{\text{data}}} [\mathcal{L}_{\text{ELBO}}(x_0; \theta)]. \quad (5)$$

因此，最大化对数似然可以通过最大化 ELBO 来实现。

(2) **用马尔可夫结构展开 ELBO** 在 DDPM 中，

$$q(x_{1:T} | x_0) = \prod_{t=1}^T q(x_t | x_{t-1}), \quad p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^T p_\theta(x_{t-1} | x_t).$$

将这些代入 ELBO，可以把 $\mathcal{L}_{\text{ELBO}}$ 写成若干条件 KL 项的和（省略与 θ 无关的常数）：

$$\mathcal{L}_{\text{ELBO}}(x_0; \theta) = C - \sum_{t=2}^T \text{KL}(q(x_{t-1} | x_t, x_0) \parallel p_\theta(x_{t-1} | x_t)) - \text{KL}(q(x_T | x_0) \parallel p(x_T)) + \mathbb{E}_q[\log p_\theta(x_0 | x_1)], \quad (6)$$

其中 C 为与 θ 无关的常数。

若进一步选取合适的方差参数化（例如固定 $p_\theta(x_{t-1} | x_t)$ 和 $p_\theta(x_0 | x_1)$ 的方差形式），可以使得

- 末端项 $\text{KL}(q(x_T | x_0) \parallel p(x_T))$ 和 $\mathbb{E}_q[\log p_\theta(x_0 | x_1)]$ 要么不依赖 θ ，要么其依赖部分可以转化为简单项；
- 依赖 θ 的主要部分集中在

$$\sum_{t=2}^T \text{KL}(q(x_{t-1} | x_t, x_0) \parallel p_\theta(x_{t-1} | x_t)).$$

因此，最大化 ELBO 等价于最小化这些条件 KL 的期望。

(3) 线性高斯情形：KL 变成均值差平方 在 DDPM 的设定中，前向后验 $q(x_{t-1} | x_t, x_0)$ 与反向模型 $p_\theta(x_{t-1} | x_t)$ 都是高斯分布：

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(\mu_q(x_t, x_0, t), \tilde{\sigma}_t^2 I_d), \quad (7)$$

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(\mu_\theta(x_t, t), \sigma_t^2 I_d), \quad (8)$$

其中 $\tilde{\sigma}_t^2$ 和 σ_t^2 仅依赖 t , I_d 为 $d \times d$ 单位矩阵。

若进一步令 $\sigma_t^2 = \tilde{\sigma}_t^2$ (或视差异为常数)，则两个高斯的 KL 可以写成

$$\text{KL}\left(q(x_{t-1} | x_t, x_0) \parallel p_\theta(x_{t-1} | x_t)\right) = \frac{1}{2\tilde{\sigma}_t^2} \|\mu_q(x_t, x_0, t) - \mu_\theta(x_t, t)\|^2 + \text{const}, \quad (9)$$

其中 “const” 不依赖 θ 。

另一方面， $\mu_q(x_t, x_0, t)$ 可以用 x_0 和 x_t 的线性组合表示，而 x_t 又满足

$$x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I_d).$$

通过代入并整理，可将 $\mu_q(x_t, x_0, t)$ 与 $\mu_\theta(x_t, t)$ 的差写成关于 ε 与 $\varepsilon_\theta(x_t, t)$ 的差，最终得到

$$\text{KL}\left(q(x_{t-1} | x_t, x_0) \parallel p_\theta(x_{t-1} | x_t)\right) = \tilde{w}_t \mathbb{E}_{x_0, \varepsilon} [\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2] + \text{const}, \quad (10)$$

其中 \tilde{w}_t 为只依赖时间步 t 的权重。

(4) 汇总得到噪声预测损失 把所有 t 的 KL 项相加，并忽略与 θ 无关的常数，可以得到一个与下式等价的目标：

$$\mathcal{L}(\theta) = \mathbb{E}_{x_0, t, \varepsilon} [w_t \|\varepsilon - \varepsilon_\theta(x_t, t)\|^2], \quad (11)$$

其中 w_t 与上述 \tilde{w}_t 对应，是仅依赖时间步的非负权重。

因此，在 DDPM 的线性高斯设定下，Step 2 中的最大似然 / 最小 KL 目标，可以通过变分下界和高斯 KL 的解析形式，转化为最小化一个“噪声预测误差”的期望损失。也就是说，只要通过随机梯度下降最小化噪声回归损失 $\mathcal{L}(\theta)$ ，就等价于在该模型类下逼近原始的最大似然目标。

根据 Step 2 的最大似然目标，可以推导出一个变分下界 (ELBO)，其中依赖 θ 的主要项可以写成若干条件 KL 的和。进一步推导可得：只要最小化下面这个“噪声预测误差”的期望，就等价于在该框架下最大化似然：

$$\mathcal{L}(\theta) = \mathbb{E}_{x_0, t, \varepsilon} [w_t \|\varepsilon - \varepsilon_\theta(x_t, t)\|^2]. \quad (23)$$

其中：

- $x_0 \sim p_{\text{data}}(x_0)$;
- $t \sim \text{Uniform}\{1, \dots, T\}$;
- $\varepsilon \sim \mathcal{N}(0, I)$;
- x_t 按式 (12) 由 (x_0, t, ε) 构造;
- $w_t \geq 0$ 为时间步权重，实践中常取 $w_t = 1$ 或简单函数。

补充 2: DDPM 的直觉

1. 直接建模复杂的 $p_{\text{data}}(x)$ 太难。

高维图像分布又多峰又奇怪，直接去学 $p_{\theta}(x)$ 或直接从噪声“一步生图”通常很不稳定 (GAN 易崩、flow 结构复杂、VAE 表达能力有限)。

2. 先把“好分布”变成“简单分布”，再学反过来。

想法是构造一个完全可控的“加噪过程”

$$x_0 \rightarrow x_1 \rightarrow \cdots \rightarrow x_T \approx \mathcal{N}(0, I),$$

把真实数据一步步「加噪、模糊、洗白」成高斯噪声。这个正向过程 q 完全由我们设计，分布形式都能写出来，也能直接采样。

真正需要学习的是**反向路径**：

$$x_T \rightarrow x_{T-1} \rightarrow \cdots \rightarrow x_0,$$

也就是“从噪声慢慢、一小步一小步去噪回到数据”的过程。

3. 每一步“去一点噪”是简单稳定的，于是把全局生成问题拆成很多小的去噪问题。

在步长足够小时，每个反向步 $p_{\theta}(x_{t-1} | x_t)$ 都近似高斯，只要知道一点“局部梯度 / 噪声”信息就能写出均值。

于是用一个神经网络在不同噪声等级 t 上，做一个非常普通的回归任务：给定 x_t ，预测它里面的噪声 ε 。

这样：

- **训练时**：从干净图 x_0 人为加噪生成 x_t ，监督信号 ε 完全已知 \Rightarrow 普通 MSE 回归，训练稳定；
- **采样时**：从高斯噪声 x_T 出发，按网络预测的一步步去噪，沿整条反向链走回 x_0 ，得到新图像。

补充 3: DDPM 中的 deep learning 部分

DDPM 里真正 *deep learning* 的部分, 就是噪声预测网络 $\varepsilon_\theta(x_t, t)$ (以及其可能顺带预测方差的分支); 其他部分主要是概率建模和手工设计的过程。

1. 不属于 deep learning 的部分 (“框架”)

- 设计前向扩散:

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t} x_{t-1}, (1 - \alpha_t)I),$$

以及其闭式形式 $q(x_t | x_0)$ 。

- 设计反向为高斯链:

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(\mu_\theta(x_t, t), \Sigma_t).$$

- 使用 ELBO / KL 将最大似然目标改写成若干条件 KL 项, 再推导成噪声 MSE 损失。

这些属于**概率图模型 + 变分推断**的理论设计层面, 本身并不依赖具体的深度网络结构。

2. 属于 deep learning 的部分 (“可学习的函数”)

- 噪声预测网络** $\varepsilon_\theta(x_t, t)$ 。

具体实现通常是 U-Net / CNN / Transformer / GNN 等大规模深度网络:

- 输入: 带噪样本 x_t (张量) 加上时间步 t 的嵌入向量;
- 输出: 与 x_t 同形状的噪声估计 $\hat{\varepsilon}$ (有时再多一个分支预测 σ_t)。

- 训练方式:** 使用 MSE 损失

$$\mathbb{E}[\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2],$$

再配合 SGD / Adam 等优化器做反向传播, 这就是标准的 deep learning 训练流程。